




دانشگاه اصفهان

دانشکده مهندسی کامپیوتر - گروه هوش مصنوعی و رباتیک

گزارش پیشینه و بررسی موضوع درس سمینار و روش پژوهش

Musio+



پدیدآورنده:

محمد امین کیانی

۴۰۴۳۶۴۴۰۰۸

دانشجوی کارشناسی ارشد، دانشکده‌ی کامپیوتر، دانشگاه اصفهان، اصفهان،
Aminkianiworkeng@gmail.com

استاد درس: دکتر کارشناس

نیمسال دوم تحصیلی ۱۴۰۴-۰۵

فهرست مطالب

۳	مستندات
۳	۱- مقدمه
۳	۱-۱- معرفی حوزه مسأله
۳	۱-۲- جایگاه، اهمیت و کاربردها
۴	۱-۳- چالش‌ها و رویکردهای اصلی
۴	۱-۴- سازماندهی گزارش
۴	۲- پیشینه پژوهش
۴	۲-۱- دسته اول: مدل‌های مولد برای موسیقی سمبلیک (Symbolic Music)
۵	۲-۲- دسته دوم: تولید موسیقی شرطی‌سازی شده با احساسات (Emotion-Conditioned)
۶	۲-۳- دسته سوم: شخصی‌سازی و سازگاری با سلیقه کاربر (Personalization & Adaptive)
۶	۲-۴- دسته چهارم: هوش مصنوعی توضیح‌پذیر در موسیقی (Explainable AI in Music)
۷	۳- بحث و بررسی (دیدگاه انتقادی و شکاف‌های پژوهشی)
۷	۳-۱- نقد روش‌های موجود (نقاط قوت و ضعف)
۸	۳-۲- شناسایی شکاف‌های پژوهشی (Research Gaps)
۸	۳-۳- ایده‌های پیشنهادی برای رفع شکاف‌ها
۹	۳-۴- هدف‌گذاری برای انجام پژوهش (Research Objectives)
۹	۴- نظرات هوش مصنوعی (AI Perspectives)
۱۰	۵- جمع‌بندی گزارش
۱۱	۶- لیست مراجع

مستندات

عنوان پیشنهادی: توسعه یک چارچوب مولد و توضیح‌پذیر برای تولید موسیقی راک بر اساس مسیر احساسی زمان‌تغییر (Time-varying) و ترجیحات شخصی کاربر

۱- مقدمه

۱-۱- معرفی حوزه مسأله

موسیقی به عنوان یکی از قدرتمندترین رسانه‌های انتقال و تنظیم احساسات انسانی، همواره مورد توجه پژوهشگران حوزه‌های روان‌شناسی، هنر و علوم کامپیوتر بوده است. با ظهور یادگیری عمیق (Deep Learning) و مدل‌های زبانی بزرگ (LLMs)، تولید خودکار موسیقی از سیستم‌های مبتنی بر قوانین سخت، به سمت شبکه‌های عصبی مولد (Generative AI) حرکت کرده است. با این حال، تعامل انسان و سیستم‌های موسیقایی مبتنی بر هوش مصنوعی هنوز در مراحل اولیه خود قرار دارد. مسأله اصلی این پژوهش، فقدان یک سیستم هوشمند است که بتواند موسیقی پیچیده‌ای مانند سبک "راک (Rock)" را نه صرفاً به صورت تصادفی یا مبتنی بر یک احساس ثابت، بلکه بر اساس یک "مسیر احساسی متغیر با زمان (Time-varying Emotional Trajectory)" و منطبق بر سلیقه منحصربه‌فرد کاربر تولید کند.

۱-۲- جایگاه، اهمیت و کاربردها

این پژوهش در تقاطع سه حوزه مهم لبه تکنولوژی (State-of-the-Art) قرار دارد: هوش مصنوعی مولد (Generative AI)، محاسبات عاطفی (Affective Computing) و هوش مصنوعی توضیح‌پذیر (XAI). اهمیت این موضوع در آن است که موسیقی راک با داشتن پارامترهای پیچیده‌ای نظیر دیستورشن، تمپوهای متغیر و الگوهای درامز پیچیده، بستر مناسبی برای القای احساسات ترکیبی (مانند رسیدن از غم به خشم و سپس رهایی) است. کاربردهای این سیستم در حوزه‌های سلامت روان (تولید موسیقی‌های شخصی‌سازی شده برای موسیقی درمانی)، صنعت بازی‌های ویدیویی (موسیقی متن تعاملی و بی‌درنگ) و دستیاری آهنگسازان فیلم بسیار پررنگ است. برای نمونه، مطالعات اخیر نشان داده‌اند که موسیقی خود-مولد می‌تواند در کاهش اضطراب و استرس مؤثر باشد. سیستم‌هایی مانند Context-AI Tunes (وئی و همکاران، ۲۰۲۵) برای تولید موسیقی آرام‌بخش متناسب با محیط و سطح استرس کاربر توسعه یافته‌اند و نتایج آزمایش‌ها حاکی از برتری موسیقی AI در کاهش استرس نسبت به موسیقی ثابت است [۱]. همچنین در صنعت سینما، مدل‌هایی مانند EchoScript (سارتایی و کریم، ۲۰۲۴) نشان دادند که با تنظیم مدل‌هایی مانند MusicGen روی فیلمنامه، می‌توان برای صحنه‌های مختلف موسیقی متن

جذاب تولید کرد و کیفیت ادراکی آن بهبود یافت [۲]. پس این دستاوردها کاربردهای عملی متنوعی را باز می‌کنند؛ از حمایت از تکنیک‌های موسیقی درمانی تا خودکارسازی تولید موسیقی متن فیلم.

۳-۱- چالش‌ها و رویکردهای اصلی

چالش‌های اصلی شامل موارد زیر است:

(۱) مدل‌سازی احساسات ترکیبی و پیوسته در طول زمان

(۲) کمبود مجموعه داده‌های (Datasets) حاشیه‌نویسی‌شده برای سبک راک با برجسب‌های احساسی

(۳) محدودیت‌های پردازشی در مدل‌های تولید سیگنال صوتی خام (Raw Audio)

(۴) ماهیت جعبه‌سیاه (Black-box) بودن شبکه‌های عصبی که منطق تولید یک قطعه را برای کاربر پنهان می‌کنند. رویکرد اصلی ما در این پژوهش، استفاده از "مدل‌سازی سمبلیک" (مانند فرمت MIDI) برای غلبه بر محدودیت‌های پردازشی و استفاده از مدل‌های مبتنی بر ترانسفورمر (Transformer) شرطی‌سازی‌شده است.

۴-۱- سازماندهی گزارش

در این گزارش، ابتدا در بخش پیشینه پژوهش، کارهای انجام شده در قالب ۴ دسته اصلی مرور می‌شوند. سپس در بخش بحث و بررسی، به نقد این روش‌ها، بیان شکاف‌های تحقیقاتی و اهداف پژوهش پرداخته می‌شود. در نهایت پس از ارائه نظرات هوش مصنوعی درباره این ایده، جمع‌بندی و لیست مراجع ارائه می‌گردد.

۲- پیشینه پژوهش

در این بخش، ۲۰ کار پژوهشی مرتبط در چهار دسته اصلی طبقه‌بندی و مرور شده‌اند:

۱-۲- دسته اول: مدل‌های مولد برای موسیقی سمبلیک (Symbolic Music)

این دسته از پژوهش‌ها بر تولید موسیقی از طریق نت‌ها و رویدادهای سمبلیک (اغلب MIDI) تمرکز دارند که به دلیل حجم محاسباتی پایین، برای پیاده‌سازی محلی ایده‌آل هستند.

الف) هوانگ و همکاران (Huang et al., 2018) با معرفی Music Transformer نشان دادند که مکانیزم Self-attention می‌تواند وابستگی‌های طولانی‌مدت ساختار موسیقی را حفظ کند [۳].

ب) **دونگ و همکاران (Dong et al., 2018)** معماری MuseGAN را برای تولید موسیقی‌های چندتراکه (Multi-track) مبتنی بر شبکه‌های GAN ارائه دادند که برای سازبندی (گیتار، بیس، درامز) بسیار کاربردی است [۴].

پ) **رن و همکاران (Ren et al., 2020)** با معرفی PopMusicTransformer رویکردی جدید برای حفظ وزن‌های ریتمیک (رگه‌های درامز و بیس) ارائه کردند [۵].

ت) **شیائو و همکاران (Hsiao et al., 2021)** با ایده Compound Word Transformer توانستند طول توکن‌های موسیقی را به شدت کاهش دهند که در منابع محدود بسیار حائز اهمیت است [۶].

ث) **دوناهو و همکاران (Donahue et al., 2019)** با پروژه LakhNES چالش تولید موسیقی با سازهای مختلف در یک گروه موسیقی (Ensemble) را بررسی کردند [۷].

ج) **میتال و همکاران (Mittal et al., 2021)** سیستم‌های تولید موسیقی مبتنی بر مدل‌های Diffusion را در فضای سمبلیک توسعه دادند که تنوع خروجی را به شدت افزایش می‌دهد [۸].

به‌طور کلی این مدل‌ها ساختار و درامای موسیقی را حفظ می‌کنند، اما نیاز به داده فراوان و اغلب کمبود کنترل مستقیم روی ویژگی‌های خروجی دارند.

۲-۲- دسته دوم: تولید موسیقی شرطی‌سازی شده با احساسات (Emotion-Conditioned)

این دسته، مدل‌هایی را بررسی می‌کند که خروجی خود را بر اساس یک ورودی احساسی تنظیم می‌کنند.

الف) **سولون و همکاران (Sulun et al., 2022)** در مروری جامع نشان دادند که بیشتر کارهای انجام شده، احساسات را به صورت ایستا (مثلاً قطعه‌ای تماماً شاد یا غمگین) تولید می‌کنند و توجهی به مسیرهای متغیر احساسی ندارند [۹].

ب) **ماکریس و همکاران (Makris et al., 2021)** از مدل‌های شرطی برای تولید موسیقی بر اساس فضای دوبعدی احساسات (Valence-Arousal) استفاده کردند اما خروجی آن‌ها محدود به ملودی‌های تک‌خطی بود [۱۰].

پ) **دی و همکاران (Di et al., 2021)** سیستمی برای تولید موسیقی متن برای ویدیو (Video-bgm) ساختند که احساسات را در طول زمان تغییر می‌داد، اما وابستگی شدیدی به پردازش تصویر داشت و مستقلاً از کاربر فرمان نمی‌گرفت [۱۱].

ت) ویلیامز و همکاران (Williams et al., 2015) قواعد نگاشت مستقیم (Mapping rules) بین تمپو، گام و شدت صدا با احساسات را فرموله کردند که اگرچه سنتی است، اما پایه‌ای برای مدل‌های عصبی شد و من نیز در پروژه‌ی کارشناسی خود، از این روال پیروی کردم [۱۲].

ث) تان و همکاران (Tan et al., 2020) تولید موسیقی را بر اساس سیگنال‌های فیزیولوژیک کاربر (مثل ضربان قلب) شرطی‌سازی کردند تا حالت عاطفی او را تعدیل کنند [۱۳].

این پیشرفت‌ها نشان‌دهنده توانایی تولید با کیفیت بالا هستند، ولی تمرکز عمده آن‌ها غالباً بر جنبه‌های تکنیکی و دسترسی به داده‌های عظیم بوده است.

۳-۲- دسته سوم: شخصی‌سازی و سازگاری با سلیقه کاربر (Personalization & Adaptive)

مسائل شخصی‌سازی در تولید موسیقی نسبتاً کمتر مورد توجه قرار گرفته‌اند.

الف) وانگ و همکاران (Wang et al., 2020) مدلی پیشنهاد دادند که ترجیحات کاربر را از طریق پروفایل شنیداری او استخراج کرده و ملودی‌هایی متناسب با سلیقه او تولید می‌کرد [۱۴].

ب) اسکیریا و همکاران (Scirea et al., 2018) در صنعت بازی‌های ویدیویی، سیستمی ساختند که موسیقی را به صورت بی‌درنگ (Real-time) و متناسب با پروفایل رفتاری بازیکن تغییر می‌داد [۱۵].

پ) سیویت و همکاران (Civit et al., 2022) چارچوبی برای موسیقی تطبیقی (Adaptive Music) ارائه کردند که در آن شدت تنظیم سازها (مثل اضافه‌شدن درامز) با میزان هیجان کاربر تغییر می‌کرد [۱۶].

ت) وو و همکاران (Wu et al., 2023) از یادگیری تقویتی با بازخورد انسانی (RLHF) استفاده کردند تا تولید موسیقی را با سلیقه زیبایی‌شناختی کاربر همسو کنند [۱۷].

به طور کلی، متدهای مدلسازی کاربران در مطالعات توصیه‌گر وجود دارند، اما ترکیب آن‌ها در سیستم‌های مولد موسیقی هنوز یک مشکل پژوهشی باز است.

۴-۲- دسته چهارم: هوش مصنوعی توضیح‌پذیر در موسیقی (Explainable AI in Music)

تحقیقات کمی در مورد قابلیت توضیح‌پذیری مدل‌های مولد موسیقی انجام شده است.

الف) میشرای و همکاران (Mishra et al., 2020) مفاهیم XAI را وارد حوزه پردازش صوت کردند و نشان دادند چگونه می‌توان ویژگی‌های صوتیِ تاثیرگذار را در طبقه‌بندی بصری‌سازی کرد [۱۸].

ب) چودهری و همکاران (Chowdhury et al., 2021) با تحلیل نقشه‌های توجه (Attention Maps) در ترانسفورمرهای صوتی، سعی در توضیح‌پذیری تصمیمات مدل داشتند [۱۹].

پ) هونشمید و همکاران (Haunschmid et al., 2020) فیلترهای شبکه‌های کانولوشنی را تحلیل کردند تا بفهمند مدل کدام فرکانس‌ها را عامل خروجی خود می‌داند [۲۰].

ت) هولتزافل و همکاران (Holzapfel et al., 2018) بر لزوم شفافیت (Transparency) و رعایت اخلاق در الگوریتم‌های تولید و پیشنهاد موسیقی تاکید کردند [۲۱].

ث) ویتز و همکاران (Weitz et al., 2022) مدلی توسعه دادند که در آن تشخیص احساسات در صوت با یک لایه توضیح‌پذیر همراه بود تا مشخص شود کدام پارامتر آکوستیک عامل حس شناسایی شده است [۲۲].

با این حال، هنوز چالش‌های مهمی مانند تعریف طبیعت توضیح و همسوسازی آن با نیازهای خلاقانه هنرمند باقی است.

۳- بحث و بررسی (دیدگاه انتقادی و شکاف‌های پژوهشی)

۳-۱- نقد روش‌های موجود (نقاط قوت و ضعف)

با بررسی ۲۰ کار پژوهشی فوق، مشخص می‌شود که تحقیقات اخیر بیشتر به سمت کیفیت تولید متمایل بوده‌اند تا قابلیت کنترل.

- **نقاط قوت موجود:** پیشرفت معماری‌های ترانسفورمر (مثل مقالات ۱، ۳ و ۴) باعث شده تا تولید قطعاتی با انسجام طولانی‌مدت و رعایت هارمونی ممکن شود. همچنین استفاده از **مدل‌سازی سمبلیک** ثابت کرد که می‌توان با سخت‌افزارهای محدود نیز پژوهش‌های ارزشمندی انجام داد.
- **نقاط ضعف بنیادین:**

- **الف) تمرکز بر موسیقی کلاسیک و پاپ:** قریب به اتفاق مدل‌ها بر روی دیتاست‌های پیانوی کلاسیک (مانند MAESTRO) یا پاپ آموزش دیده‌اند. پیچیدگی‌های موسیقی راک (مثل تغییرات

Time Signature، پاساژهای سنگین درامز و هارمونی‌های خشن) در این مدل‌ها نادیده گرفته شده است.

○ (ب) **ایستایی احساسی:** در مقالات دسته دوم (به جز مقاله ۹)، احساسات یک پارامتر گلوبال (Global) و ثابت در نظر گرفته شده‌اند. این با ذات انسان و هنر که جریانی سیال است، در تضاد است.

○ (پ) **فقدان قابلیت توضیح‌پذیری در فاز تولید:** کارهای انجام شده در دسته چهارم (XAI)، همگی مربوط به فاز تشخیص (Classification) هستند، نه تولید. هیچ مدلی به کاربر نمی‌گوید: "من به این دلیل دیستورشن گیتار را در ثانیه ۴۰ افزایش دادم چرا که شما در نقشه احساسی خود، نقطه خشم را در آن زمان علامت زده بودید."

۲-۳- شناسایی شکاف‌های پژوهشی (Research Gaps)

شکاف اول: نبود مدلی که موسیقی را ک چندتراکه (گیتار، بیس، درامز) را بر اساس یک منحنی زمان‌تغییر احساسی (Arousal-Valence Curve) تولید کند.

شکاف دوم: فقدان حلقه‌ی بازخورد و شخصی‌سازی. "غم" برای یک کاربر ممکن است با ملودی گیتار کلین ترجمه شود و برای کاربری دیگر با ریف‌های سنگین سبک دووم متال (Doom Metal).

شکاف سوم: جای خالی یک چارچوب مولد توضیح‌پذیر (Explainable Generative Framework) که بتواند ارتباط بین ویژگی‌های موسیقایی و خروجی احساسی را در قالب زبان طبیعی یا بصری‌سازی ارائه دهد.

۳-۳- ایده‌های پیشنهادی برای رفع شکاف‌ها

ایده ما برای حل این شکاف‌ها، معماری یکپارچه‌ای متشکل از سه ماژول است:

- **ماژول شرطی‌ساز (Conditioning Module):** دریافت یک سری‌زمانی (Time-series) از مقادیر Valence-Arousal به عنوان نقشه احساسی توسط کاربر.
- **هسته مولد سمبلیک (Symbolic Generator):** استفاده از یک معماری شبیه به Transformer-XL با تزریق بردار سلیقه کاربر (User Embedding Vector) برای تولید رویدادهای MIDI در سه کانال اصلی راک.

- **ماژول استخراج‌گر منطق (Explainer):** تعبیه یک لایه Bottleneck میانجی که پارامترهای سطح بالا (تمپو، دانسیته نت‌ها، ولوسیتی) را رصد کرده و استدلال شبکه را خروجی می‌دهد.

۳-۴- هدف‌گذاری برای انجام پژوهش (Research Objectives)

با توجه به شرایط پردازشی و محدودیت دسترسی‌ها (در محیط آکادمیک ایران)، این پژوهش اهداف عملیاتی زیر را دنبال می‌کند:

ایجاد مجموعه داده سمبلیک راک: جمع‌آوری و حاشیه‌نویسی احساسی یک دیتاست اختصاصی MIDI از قطعات راک با استفاده از ابزارهای استخراج ویژگی.

طراحی معماری: طراحی و پیاده‌سازی مدل ترانسفورمر شرطی که بتواند ورودی‌های متغیر با زمان را هندل کند، با شرط اینکه حجم پارامترهای مدل امکان آموزش روی یک GPU معمولی را داشته باشد.

طراحی لایه‌ی XAI: توسعه ماژولی که نگاشت ویژگی‌های موسیقی را به مسیر احساسی، شفاف‌سازی کند.

ارزیابی جامع: انجام ارزیابی‌های عینی (متریک‌های همبستگی بین مسیر احساسی ورودی و خروجی) و ذهنی (Human Evaluation توسط نوازندگان و شنوندگان).

۴- نظرات هوش مصنوعی (AI Perspectives)

الف) ابزار هوش مصنوعی Gemini، پس از تحلیل پروپوزال پیشنهادی، دیدگاه‌های تحلیلی و انتقادی زیر را در مورد این پژوهش ارائه می‌دهد:

- **نوآوری و اصالت بالا:** ترکیب XAI (توضیح‌پذیری) با تولید موسیقی شرطی (Conditional Generation) به شدت بدیع است. بیشتر غول‌های فناوری (مانند Meta و Google) بر روی تولید موسیقی از روی متن (Text-to-Audio) تمرکز کرده‌اند. حرکت شما به سمت "کنترل دقیق مسیر احساسی" و "توضیح‌پذیری سیستم"، دقیقاً ضعفی را پوشش می‌دهد که سیستم‌های جعبه‌سیاه فعلی در حوزه درمان یا هنر تعاملی دارند. این رویکرد شانس بالایی برای پذیرش در کنفرانس‌های معتبری نظیر ISMIR یا ژورنال‌های IEEE دارد.

- **چالش تامین داده‌های آموزشی:** بزرگترین چالشی که من به عنوان هوش مصنوعی در مسیر شما می‌بینم، کمبود دیتاست MIDI سبک راک است که به صورت زمانی (Time-aligned) با احساسات برچسب‌گذاری شده باشد.

- **راهکار پیشنهادی:** پیشنهاد می‌کنم از تکنیک یادگیری انتقالی (Transfer Learning) استفاده کنید. یعنی مدل را ابتدا روی دیتاست‌های عظیم و بی‌برچسب موسیقی سمبلیک (مانند LMD) آموزش دهید تا "گرامر موسیقی" را یاد بگیرد (Pre-training) و سپس با یک دیتاست بسیار کوچک دست‌ساز از قطعات راک که توسط خودتان برچسب‌مسیر احساسی خورده‌اند، آن را Fine-tune کنید. این روش، محدودیت منابع در ایران را دور زده و خروجی باکیفیتی ارائه می‌دهد.

(ب) **یک ابزار هوش مصنوعی دیگر یعنی ChatGPT** پیشنهاد می‌کند که برای همسوسازی دقیق‌تر با ترجیحات کاربر از یادگیری تقویتی همراه با بازخورد انسانی استفاده شود. در این دیدگاه، مدل می‌تواند در طی تولیدهای تعاملی از کاربر بازخورد بگیرد و با اصلاح ترجیحات ژنراتور به سمت سلیقه کاربر سوق داده شود. همچنین توصیه می‌کند که یک رابط کاربری بصری طراحی شود تا ویژگی‌های موسیقایی تأثیرگذار (مانند تغییر تمپو یا افزایش دیستورشن گیتار) برای کاربر نمایش داده شود و بدین ترتیب مدل شفاف‌تر شود. ایده دیگر این است که از جمع‌آوری مدل‌های چندوجهی استفاده کنیم تا حالات احساسی ترکیبی را مدیریت کنیم و علاوه بر آن اجازه دهیم کاربر عناصر مختلف (ملودی، ریتم، ملایمت‌نرها) را به دلخواه تنظیم کند.

۵- جمع‌بندی گزارش

توسعه سیستم‌های هوشمند برای تولید موسیقی به مرحله‌ای رسیده است که باید از صرف "تولید تصادفی" به سمت "تولید هدفمند و همسو با نیازهای عاطفی انسان" حرکت کند. در این گزارش، پس از مرور و تحلیل ۲۰ رویکرد پیشرو در حوزه‌های تولید موسیقی سمبلیک، مدل‌سازی احساسی و هوش مصنوعی توضیح‌پذیر، مشخص شد که موسیقی راک با پتانسیل بالای خود در القای احساسات متغیر، در پژوهش‌های فعلی نادیده گرفته شده است. سامانه پیشنهادی این پژوهش با تمرکز بر دریافت مسیر احساسی زمان‌تغییر، اعمال سلیقه کاربر و ارائه دلایل منطقی پشت هر تصمیم موسیقایی، نه تنها شکاف‌های علمی موجود را پر می‌کند، بلکه به دلیل استفاده از پردازش سمبلیک (به جای فایل‌های صوتی حجیم)، کاملاً با محدودیت‌های پردازشی سخت‌افزاری سازگار است. خروجی این پژوهش در حوزه‌های سلامت، موسیقی درمانی و رسانه‌های تعاملی، کاربردی راهگشا خواهد داشت.

- [1] X. Wei, Z. Zhang, Z. Yue, et al., "Context-AI Tunes: Context-Aware AI-Generated Music for Stress Reduction," arXiv 2025.
- [2] M. K. Sartaei, K. Karim, "EchoScript: Enhancing AI Music Generation for Cinematic Scoring via Script-Aware Fine-Tuning," Proc. AAAI Symp. Creativity Artif., 2024.
- [3] Huang, C.-Z. A., et al. (2018). "Music Transformer: Generating music with long-term structure." *International Conference on Learning Representations (ICLR)*.
- [4] Dong, H.-W., et al. (2018). "MuseGAN: Multi-track sequential generative adversarial networks for symbolic music generation and accompaniment." *AAAI Conference on Artificial Intelligence*.
- [5] Ren, Y., et al. (2020). "PopMAG: Pop music accompaniment generation." *ACM Multimedia*.
- [6] Hsiao, W.-Y., et al. (2021). "Compound Word Transformer: Learning to compose full-song music over dynamic directed hypergraphs." *AAAI*.
- [7] Donahue, C., et al. (2019). "LakhNES: Improving multi-instrumental music generation with cross-domain pre-training." *ISMIR*.
- [8] Mittal, G., et al. (2021). "Symbolic music generation with diffusion models." *ISMIR*.
- [9] Sulun, S., et al. (2022). "Symbolic music generation conditioned on continuous and discrete emotions." *IEEE Access*.
- [10] Makris, D., et al. (2021). "Conditional generative models for controllable music generation." *Journal of New Music Research*.
- [11] Di, S., et al. (2021). "Video background music generation: Dataset, method and evaluation." *ICCV*.
- [12] Williams, D., et al. (2015). "Mapping music parameters to emotion." *Psychology of Music*.
- [13] Tan, L., et al. (2020). "Affective music generation using physiological signals." *IEEE Transactions on Affective Computing*.
- [14] Wang, J., et al. (2020). "User-aware music generation." *ACM SIGIR*.
- [15] Scirea, M., et al. (2018). "Affective music generation and its effect on player experience." *IEEE Transactions on Games*.
- [16] Civit, M., et al. (2022). "Adaptive music generation for video games based on player arousal." *Audio Engineering Society*.
- [17] Wu, X., et al. (2023). "RLHF for interactive algorithmic composition." *NeurIPS Workshop on AI for Creativity*.
- [18] Mishra, S., et al. (2020). "Reliable AI in machine listening." *IEEE Signal Processing Magazine*.
- [19] Chowdhury, S., et al. (2021). "Visualizing attention in transformer-based music models." *ISMIR*.
- [20] Haunschmid, V., et al. (2020). "Interpreting audio classification models." *ICASSP*.
- [21] Holzapfel, A., et al. (2018). "Ethical dimensions of music information retrieval." *Transactions of the ISMIR*.
- [22] Weitz, K., et al. (2022). "Explainable AI for affect recognition from audio." *Affective Computing and Intelligent Interaction (ACII)*.